Predicción de mora en préstamos hipotecarios para decisiones de otorgamiento de crédito

Informe final — Proyecto Final Integrador (Unidad 10)

Diplomatura en Ciencia de Datos y Análisis Avanzado — UTN BA

Equipo N.º 24

Ailin Soriano · Fernanda Pardo · Pablo Magnino · Germán Langoni

26 de octubre de 2026

Índice. 1. Resumen ejecutivo · 2. Definición del problema y relevancia · 3. Datos y metodología · 4. Modelado y evaluación · 5. Interpretación del modelo · 6. Impacto en el negocio, riesgos y ética · 7. Conclusiones y recomendaciones · Anexos

1. Resumen ejecutivo

Problema. Un banco que otorga créditos hipotecarios sin evaluarlo correctamente pierde capital cuando el solicitante entra en mora, o tiene un costo de oportunidad cuando rechaza a alguien que habría pagado. Este proyecto estima, a partir de los datos de la solicitud, la probabilidad de mora, y aplica una regla de decisión con fundamento económico para determinar la decisión final con respecto al crédito.

Solución. Un modelo XGBoost que estima, con los datos de la solicitud, la probabilidad de mora, y una regla de decisión económica que rechaza sólo cuando la pérdida esperada supera al margen esperado, considerando un corte fijo. Un tope comercial limita el rechazo a 1 de cada 5 solicitudes.

Indicador (test: 33.335 solicitudes)	Mejor regla LTV/DTI	Modelo
Moras detectadas, rechazando como máximo 20%	31,3%	**54,6%**
Pérdida crediticia (simulación)	USD 126,2 M	**USD 71,3 M**
Resultado neto de la cartera (simulación)	USD 122,9 M	**USD 178,9 M**
PR-AUC (azar = 0,16)	—	**0,621**

Tabla 1. Política recomendada frente a la mejor regla simple con el mismo tope de rechazo. Cifras en USD simuladas con margen 3% y recupero de la garantía 70%.

Resultado. Con el mismo tope de rechazo, el modelo detecta 1,7 veces más moras que la mejor regla simple construida con LTV y deuda/ingreso (DTI), y mejora el resultado simulado en USD 56 M.

Hallazgo clave de datos. El 10% del dataset (15.333 solicitudes) es un bloque con 100% de mora que funciona como fuga de información. Decidimos excluirlo.

2. Definición del problema y relevancia

La decisión que apoyamos es **aprobar o rechazar una solicitud de crédito hipotecario** al momento de la presentación. El usuario es el área de riesgo crediticio, como así también el solicitante que tiene derecho a conocer los motivos del rechazo. El modelo tiene un impacto significativo, ya que

permite evaluar operaciones por aproximadamente USD 44.000 millones al año[1], y cada decisión acertada puede contribuir a reducir la mora y generar importantes beneficios económicos.

Situación	Lectura estadística	Costo para el banco
Aprobar a quien entra en mora	Falso negativo	Capital no recuperado tras ejecutar la garantía (LGD × monto)
Rechazar a quien habría pagado	Falso positivo	Margen perdido y cliente que se va a la competencia
Predecir siempre "no mora"	Accuracy 84%	Parece buena y no detecta ninguna mora

Tabla 2. Los errores y su costo.

El error más caro por operación es aprobar una mora con poca garantía: aunque el préstamo sea menor que la tasación, la casa ejecutada se vende con descuento, con costos y años de demora. Sin embargo, rechazar de más tampoco es gratis, por eso no optimizamos una métrica estadística sino el **resultado económico**, que pone ambos errores en dólares.

Objetivo medible, fijado antes de modelar: (1) PR-AUC en test de al menos el doble de la tasa de mora; (2) resultado económico mayor que el de la mejor regla simple, (3) rechazo de no más del 20% de las solicitudes.

Hipótesis. H1: más deuda sobre ingreso o menos ingreso, más mora. H2: más LTV (menos colchón de garantía), más mora. H3: los productos con pago global al final, amortización negativa o destino comercial son más riesgosos. H4: menor puntaje crediticio, más mora.

3. Datos y metodología

Fuente. *Loan Default Dataset*, Kaggle (usuario yasserh). 148.670 solicitudes de 2019, 34 columnas, una fila por solicitud, sin identificadores personales. Es crédito hipotecario de un mercado tipo EE.UU.: incluye tasación, LTV y tipo de garantía.

[1] Cálculo propio en base al dataset (importe total de préstamos, contemplando solicitudes con tasación).

Diccionario (las 10 variables principales).

Variable	Qué es
`loan_amount`	Monto del préstamo (USD)
`property_value`	Valor de tasación de la garantía (USD)
`LTV`	Préstamo / tasación × 100
`income`	Ingreso del solicitante. **Es mensual**, no anual: mediana USD 5.760 para préstamos de USD 296.500
`dtir1`	Deuda total / ingreso (%)
`Credit_Score`	Puntaje crediticio (escala 500-900)
`Credit_Worthiness`	Calificación de solvencia del originador (l1/l2)
`lump_sum_payment`	El crédito tiene un pago global al final (balloon)
`credit_type`	Buró que informó el puntaje
`Status`	1 = mora, 0 = al día

Hallazgos.

Hallazgo de calidad	Decisión y motivo
rate_of_interest,Interest_rate_spread, Upfront_charges vacías en el 100% de las moras	**Excluidas**: son condiciones posteriores a la aprobación y su ausencia delata el target
Bloque de 15.333 filas (buró EQUI o sin tasación) con **100% de mora**	**Filas excluidas**: Ver Figura 1. En producción, una solicitud sin tasación va a revisión manual
Gender y age	**Excluidas del modelo** para no sesgarlo. Se usan solo para auditar (sección 6)
Credit_Worthiness	**Excluida**: el modelo no depende de la clasificación del sistema actual
submission_of_application	**Excluida**: se desconoce su significado (no se podría justificar un rechazo basado en ella)
dtir1 e income vacíos (6,6%)	Los árboles aprenden a dónde mandar el vacío; la logística imputa mediana + indicador. Ajuste solo con entrenamiento
348 solicitudes con ingreso 0	**No se ponen a cero ni se eliminan**: se marcan con una variable indicadora (ingreso_cero)
Montos e ingresos extremos	Legítimos: no se eliminan; log(1+x) solo para la logística
income es mensual (mediana USD 5.760)	Se crea variable préstamo/ingreso anual (lti)

Tabla 3. Hallazgos de calidad y decisiones de limpieza.

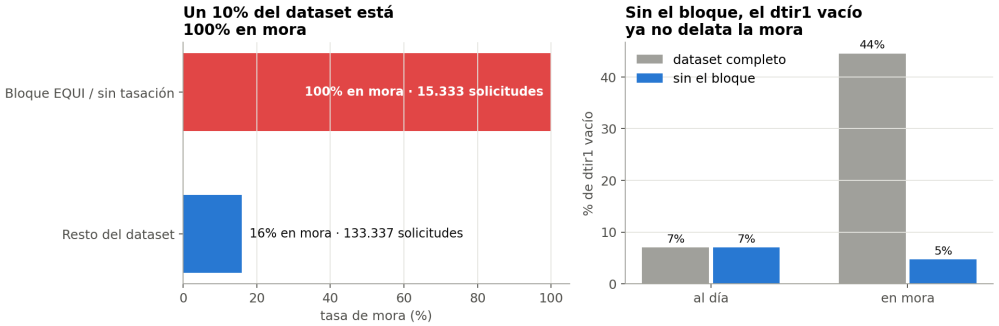


Figura 1. Izquierda: el bloque EQUI / sin tasación tiene 100% de mora. Derecha: sin ese bloque, los nulos de dtir1 (ratio deuda sobre ingreso) dejan de delatar la mora.

La variable credit_type indica qué buró informó el historial: CIBIL, CRIF y Experian tienen 16% de mora; Equifax (EQUI), 100%. El bloque EQUI / sin tasación explica el 42% de todas las moras del dataset. Ningún buró tiene clientes que entran en mora el 100% de las veces, y ningún banco otorga una hipoteca sin tasar. Si el modelo lo ve, aprende a reconocer el bloque y no a evaluar riesgo. Sin él quedan 133.337 solicitudes con 16,0% de mora.

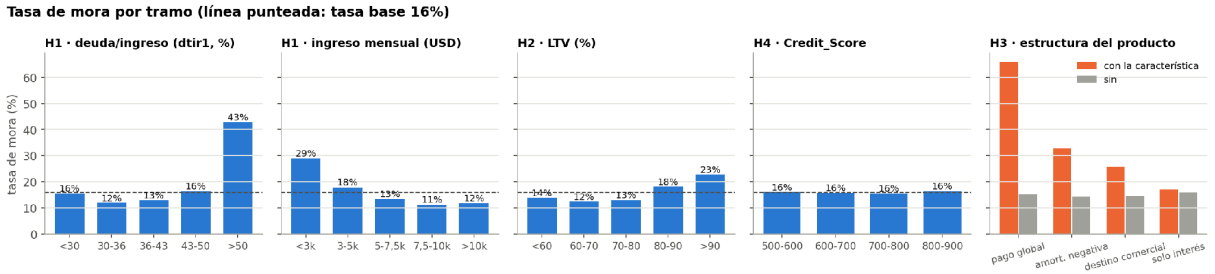


Figura 2. Tasa de mora por tramo de cada hipótesis, sin el bloque EQUI/sin tasación.

Conclusiones del EDA. H1 se ve con claridad: la mora pasa de 12% a 43% cuando la deuda/ingreso supera el 50%, y, por otra parte, aumenta cuando cae el ingreso. H2 se ve más suave: 13% con LTV menor a 80% y 23% por encima de 90% (80% es justamente el umbral a partir del cual el mercado de EE.UU. exige seguro hipotecario). H3 es la señal más fuerte: los créditos con pago global al final tienen 66% de mora contra 15%. **H4 no se ve**: la mora es plana (16%) en todos los tramos de Credit_Score, algo imposible en un banco real, que sugiere que el dataset es en parte sintético.

Metodología. Seguimos CRISP-DM: negocio (sección 2), comprensión y preparación de datos (sección 3), modelado y evaluación (4), interpretación (5) y despliegue simulado (6). Todas las transformaciones viven en un pipeline que se ajusta solo con datos de entrenamiento, con semillas fijas.

Diseño de validación	Pregunta que responde
Partición estratificada 75% desarrollo / 25% test	El test se usa una sola vez, con todo decidido
Validación cruzada de 5 folds sobre desarrollo	¿Qué algoritmo ordena mejor el riesgo?

Diseño de validación	Pregunta que responde
5 semillas por modelo (1.000 remuestreos)	¿La diferencia es real o es ruido?
Curva de aprendizaje y ablaciones	¿Alcanzan los datos? ¿Qué aporta cada bloque?

Tabla 4. Esquema de validación. No hay validación temporal posible: todo el dataset es de 2019.

4. Modelado y evaluación

Modelo económico. Las cifras en dólares son una **simulación** con dos supuestos fijados antes de modelar: margen de 3% del monto y pérdida ante mora LGD = 1 − 0,70 × tasación / monto, con piso de 5%[2]. El recupero de 70% es coherente con la evidencia: las ventas por ejecución hipotecaria en EE.UU. se hacen con un 27% de descuento promedio[3], a lo que se suman costos judiciales y demoras. Conviene rechazar cuando p × LGD > (1 − p) × margen, es decir, con un umbral distinto para cada solicitud: un crédito muy garantizado se rechaza recién con 37,5% de probabilidad de mora, uno con poca garantía con 7%.

Algoritmos y reglas de selección. Se evaluaron cuatro modelos: regresión logística, Random Forest, HistGradientBoosting y XGBoost. El entrenamiento se realizó sin ponderar las clases. Para comparar el desempeño de los modelos se utilizó como métrica principal PR-AUC, calculada mediante validación cruzada y, ante los casos de empates (menos de un desvío del mejor), se calculó la calibración (Brier) dado que la regla económica usa la probabilidad como tal.

Modelo	PR-AUC (CV)	ROC-AUC (CV)	Brier (CV)
HistGradientBoosting	0,618 ± 0,006	0,814	0,0922
XGBoost	**0,618 ± 0,008**	0,814	**0,0921**
Random Forest	0,585 ± 0,008	0,804	0,0974
Regresión logística	0,403 ± 0,007	0,722	0,1174

Tabla 5. Validación cruzada de 5 folds sobre desarrollo (100.002 solicitudes). Corte de empate: 0,612.

XGBoost y HistGradientBoosting quedan empatados (0,618): elegimos XGBoost (calibración menor). La logística queda 22 puntos atrás: el riesgo depende de umbrales y combinaciones que un modelo lineal no captura. Ajustar los hiperparametros no nos fue útil, las 15 configuraciones que probamos rindieron igual que la de fábrica y agregar filas tampoco mostró mejoras. En conclusión, el modelo ya aprovecha casi todo lo que los datos tienen para dar, y para notar una diferencia harían falta variables nuevas (por ejemplo, el historial de pagos real).

[2] Fuente: el piso de Basilea III para hipotecas.
[3] Campbell, Giglio y Pathak, 2011.

Un tope de 20% en las operaciones anuales no es viable ya que si se agotara en septiembre, por ejemplo, habría que aprobar a todos hasta fin de año, por tal motivo usamos un corte fijo. Con los datos de desarrollo calculamos qué pérdida esperada deja afuera al 20% de las solicitudes (USD 1.204), y cada solicitud cuya pérdida esperada lo supere se rechaza. En el test rechazó el 19,4%, y repartido en 12 meses al azar, entre 18,2% y 20,2%. Si en la práctica el rechazo mensual se alejara mucho del 20%, sería una alarma de que cambiaron los clientes o la economía.

Política en test	% rechazo	Moras detectadas	Pérdida crediticia	Resultado neto
Aprobar todo	0%	0%	USD 230,3 M	USD 51,3 M
Regla propuesta (LTV > 80 y DTI > 45)	9,8%	16,6%	USD 170,5 M	USD 87,2 M
Mejor regla LTV/DTI (LTV > 85 o DTI > 50)	30,5%	46,7%	USD 69,5 M	USD 133,5 M
Mejor regla con tope 20% (LTV > 95 o DTI > 50)	15,2%	31,3%	USD 126,2 M	USD 122,9 M
Modelo XGBoost con tope 20%	**19,4%**	**54,6%**	**USD 71,3 M**	**USD 178,9 M**

Tabla 6. Comparación con los benchmarks. La mejor regla se buscó entre 143 combinaciones de cortes sobre desarrollo, no sobre test.

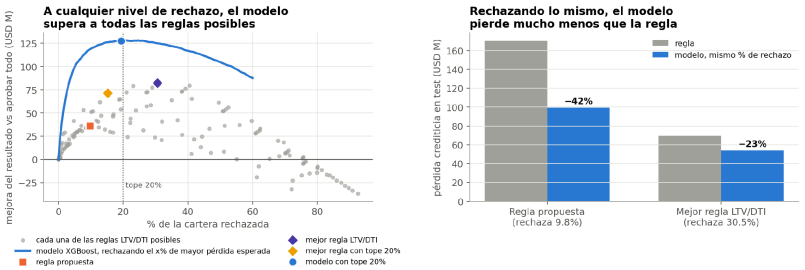


Figura 3. Izquierda: mejora del resultado según el % de cartera rechazada, para el modelo y cada regla LTV/DTI posible. Derecha: pérdida crediticia de cada regla y del modelo rechazando la misma cantidad de solicitudes.

¿Cuánto pierde el banco con la regla y con el modelo? Al comparar las alternativas con una misma tasa de rechazo, el modelo permite reducir las pérdidas un 42% respecto de la regla propuesta y un 23% frente a la mejor regla basada en LTV/DTI (Figura 3, derecha). Además, como se observa en la Figura 3 (izquierda), ninguna de las reglas LTV/DTI alcanza el desempeño del modelo, independientemente del nivel de rechazo considerado. Esto también pone en evidencia las limitaciones de los criterios tradicionales: la regla propuesta tiene una precisión del 27%, apenas por encima de la tasa de mora general del 16%, mientras que aplicar el criterio de mercado de

rechazar todas las solicitudes con un LTV superior al 80% implicaría dejar afuera al 38% de los solicitantes, aunque solo el 20% de ese grupo presenta mora.

Métrica en test (política recomendada)	**Logística**	**Random Forest**	**HistGB**	**XGBoost**
PR-AUC	0,400	0,593	0,621	**0,621**
ROC-AUC	0,716	0,802	0,814	**0,813**
Precisión / Recall	0,33 / 0,41	0,43 / 0,52	0,45 / 0,55	**0,45 / 0,55**
F1	0,37	0,47	0,49	**0,49**
Accuracy	0,78	0,81	0,82	**0,82**
Resultado neto (USD M)	141,2	175,0	179,3	**178,9**

Tabla 7. Evaluación única sobre el test (33.335 solicitudes, 5.327 moras). Cada modelo con su propio corte fijo calibrado en desarrollo.

Con estos resultados se cumplen los tres objetivos que fijamos antes de modelar: el PR-AUC de 0,621 casi cuadruplica la tasa de mora, la ventaja sobre la mejor regla es claramente mayor que cero y el rechazo queda en 19,4%. Llama la atención que la accuracy del modelo (82%) sea menor que la de predecir siempre "no mora" (84%), pero es esperable: el modelo rechaza a propósito a algunos buenos pagadores, porque cada mora que evita vale varias veces el margen que deja de ganar. Además, ordena bien el riesgo: el 10% de solicitudes que marca como más riesgosas tiene 71% de mora.

5. Interpretación del modelo

Usamos SHAP sobre 3.000 solicitudes del test.

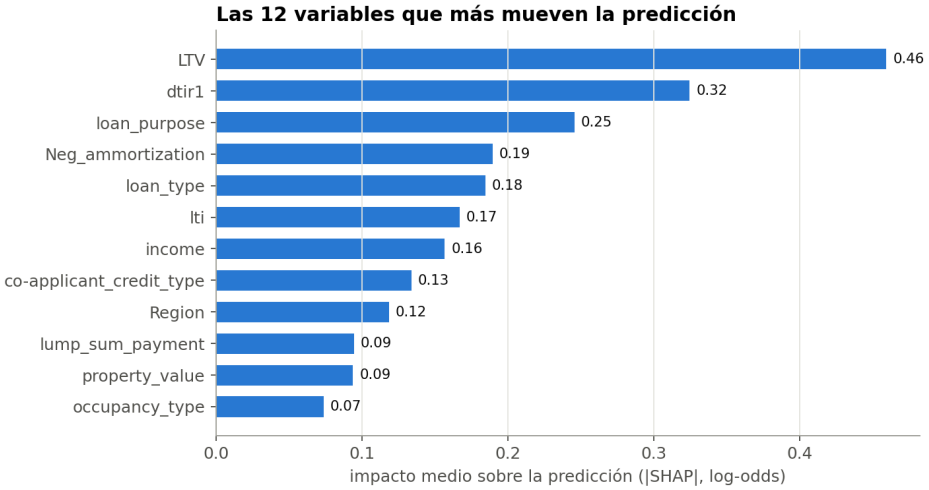


Figura 4. Importancia SHAP global: las 12 variables que más mueven la predicción.

Las variables más influyentes son LTV (garantía), la deuda/ingreso, el préstamo/ingreso, el ingreso y la estructura del producto.

Ablación (se reentrena el modelo)	**Δ PR-AUC**	**Δ resultado**	**Lectura**
H1 · sin capacidad de pago	−12,4 p.p.	−USD 22,5 M	Respaldada: el bloque más importante
H3 · sin estructura del producto	−10,4 p.p.	−USD 17,0 M	Respaldada
H2 · sin garantía (LTV, tasación)	−6,6 p.p.	−USD 14,2 M	Respaldada
H4 · sin Credit_Score	+0,1 p.p.	−USD 0,3 M	**No respaldada**: no aporta

Tabla 8. Ablaciones sobre el mismo test (promedio de 3 semillas, rechazando el 20% de mayor pérdida esperada).

Los resultados indican que ampliar la cantidad de registros de entrenamiento aporta mejoras marginales (1 punto de PR-AUC al pasar de 40.000 a 80.000 filas), por lo que, de continuar el proyecto, priorizaríamos incorporar nuevas variables relevantes, como el historial real de pagos, la antigüedad laboral y datos temporales.

6. Impacto en el negocio, riesgos y ética

Simulación de tres años. Tomamos el volumen del propio dataset: 133.337 solicitudes por año evaluadas por el modelo (las que llegan sin tasación van a revisión manual). Comparamos contra lo que el banco podría hacer sin modelo: la mejor regla simple con el mismo tope.

El primer año incluye 3 meses de piloto sin beneficio.

Escenario (margen · recupero · % de la ventaja que se mantiene en la realidad)	Ventaja anual (USD M)	Neto año 1 (USD M)	Neto 3 años (USD M)
Pesimista (2% · 80% · 50%)	59,9	44,9	164,7
Base (3% · 70% · 75%)	168,0	126,0	462,0
Optimista (4% · 60% · 100%)	387,1	290,4	1.064,7

Tabla 9. Como el desempeño del modelo en condiciones reales puede diferir del observado en el conjunto de prueba, en cada escenario suponemos que sólo se conserva una parte de la mejora obtenida durante la evaluación. No incorporamos costos de CAPEX (inversión inicial en infraestructura y tecnología) ni de OPEX (costos operativos y de mantenimiento), ya que no contamos con información suficiente para estimarlos de manera confiable. Por lo tanto, los resultados deben interpretarse como una estimación del beneficio potencial del modelo, antes de considerar los costos asociados a su implementación y operación.

Los montos son grandes porque la cartera es grande: aun en el escenario base, la ventaja es el 0,4% de lo que se presta. **El riesgo no es económico sino de validez**: que el modelo rinda igual con datos reales. La ventaja sobre la mejor regla es positiva en los 12 escenarios de margen (2% a 5%) y recupero (60% a 80%) probados sobre el test, entre USD 28 y 90 M; lo que sí cambia según los supuestos es cuánto conviene rechazar (10% a 46%), y por eso el tope. Además, la tasa de mora del dataset (16%) es alta para una cartera hipotecaria: en una cartera más sana la ventaja en dólares sería menor.

Auditoría ética. El modelo no usa género ni edad, pero puede reconstruirlos a partir de otras variables correlacionadas. Por tal motivo, auditamos el resultado por grupo (cuántos buenos pagadores de cada grupo quedan rechazados).

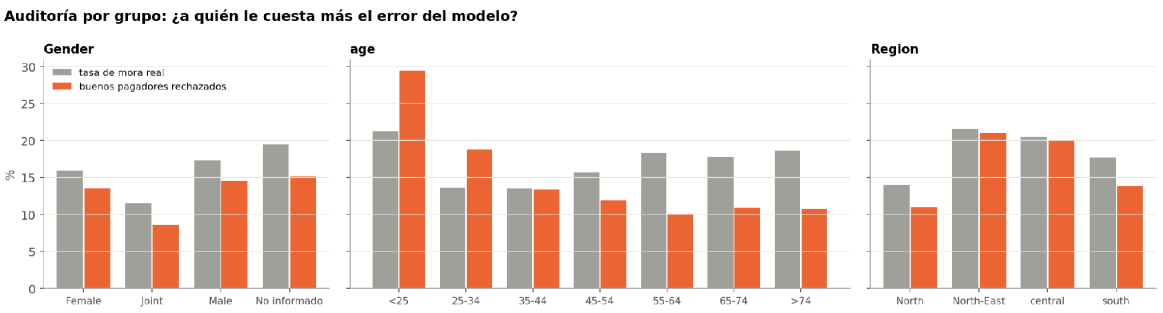


Figura 5. Tasa de mora real y buenos pagadores rechazados por grupo, con la política recomendada.

Por género y región, los rechazos siguen a la tasa de mora real. **Por edad hay una señal de sesgo:** los de 25 a 34 años tienen menos mora (13,6%) que los de 55 a 64 (18,3%), pero más buenos pagadores rechazados (18,8% contra 10,1%). Nuestra lectura es que el modelo los rechaza porque ganan poco para lo que piden. Optamos por no establecer umbrales diferenciados por edad, ya que esto implicaría incorporar explícitamente esa variable en la decisión crediticia. En cambio, identificamos esta situación como un riesgo potencial de sesgo, que deberá evaluarse junto con el área legal y monitorearse en cada reentrenamiento del modelo.

Riesgo	**Mitigación**
Dataset con artefactos y en parte sintético	Reentrenar con datos reales
Sin dimensión temporal (todo 2019)	Validar en un período posterior; monitorear el rechazo y la mora cada mes
Supuestos económicos sin fuente propia	Sensibilidad en 12 escenarios; validar margen y recupero con finanzas
La pérdida no considera el seguro hipotecario (en EE.UU., usual con LTV mayor a 80%)	Declarado: LGD puede sobreestimar la pérdida y, con ella, el valor en USD del modelo
Sesgo por edad vía variables correlacionadas	Auditoría por grupo en cada reentrenamiento; revisión legal
El banco solo observa la mora de quien aprobó	Reservar una pequeña cuota de aprobaciones fuera del modelo
Privacidad	Datos sin identificadores; en producción, minimización y control de accesos (Ley 25.326)

Tabla 10. Riesgos y mitigaciones.

Escalabilidad. El modelo entrena en segundos y puntúa en milisegundos; el pipeline se reutiliza para otros créditos con garantía cambiando las variables de garantía.

7. Conclusiones y recomendaciones

- El hallazgo más importante es de datos: un 10% del dataset es un artefacto con 100% de mora que infla cualquier métrica. Detectarlo bajó el PR-AUC de 0,84 a 0,62, pero ahora mide riesgo real.
- XGBoost, elegido con una regla definida antes de ver el test, ordena el riesgo 3,9 veces mejor que el azar (*PR-AUC 0,621*).
- Con el mismo tope de rechazo del 20%, detecta 54,6% de las moras contra 31,3% de la mejor regla LTV/DTI, y mejora el resultado simulado en USD 56 M sobre el test.
- H1, H2 y H3 se sostienen; H4 no. Usamos solo variables que podemos explicar: excluir Credit_Worthiness y submission_of_application cuesta menos del 3% del resultado.
- Los datos alcanzan para este modelo, pero lo que falta para mejorarlo son variables nuevas, no más filas.
- Hay una señal de sesgo por edad, que leemos como efecto del ingreso y declaramos como riesgo.

Recomendaciones y pasos sugeridos:

1. No desplegar todavía.
2. Reentrenar con datos reales y fechados del banco
3. Validar margen y recupero con finanzas
4. Revisar el sesgo por edad con legales
5. Piloto de 3 meses en el que el modelo recomienda y el analista decide, midiendo mora, aprobaciones, rechazo mensual y buenos pagadores rechazados por grupo. Escalar solo si el piloto confirma la ventaja.

Anexo A. Deciles de riesgo (test)

Decil	Solicitudes	Moras	Tasa de mora	Probabilidad media predicha	Lift	% de moras acumulado
1	3.334	2.375	71,2%	67,1%	4,46	44,6%
2	3.333	792	23,8%	24,3%	1,49	59,5%
3	3.334	533	16,0%	16,0%	1,00	69,5%
4	3.333	395	11,9%	12,2%	0,74	76,9%
5	3.333	322	9,7%	9,9%	0,60	82,9%
6	3.334	261	7,8%	8,2%	0,49	87,8%
7	3.333	239	7,2%	6,8%	0,45	92,3%
8	3.334	174	5,2%	5,7%	0,33	95,6%
9	3.333	150	4,5%	4,6%	0,28	98,4%
10	3.334	86	2,6%	3,2%	0,16	100,0%

Tabla A1. Deciles de riesgo en el test, de mayor a menor probabilidad de mora predicha.

La probabilidad media predicha coincide con la tasa observada en cada decil: el modelo está calibrado.

Anexo B. Figuras complementarias

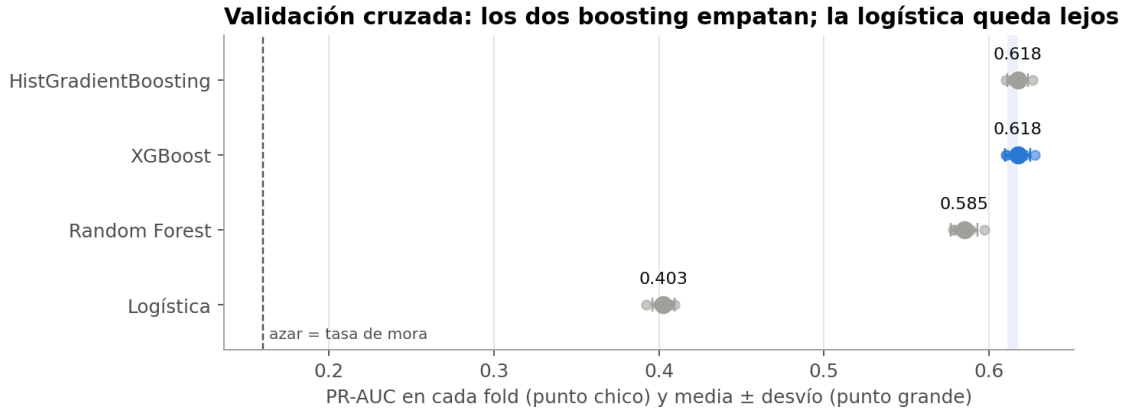


Figura B1. Validación cruzada: PR-AUC en cada fold y media ± desvío por algoritmo.

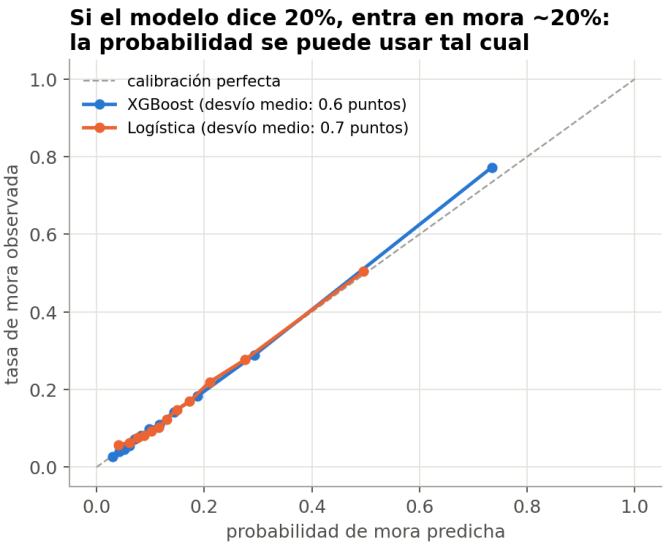


Figura B2. Calibración: probabilidad de mora predicha contra tasa de mora observada, con las predicciones fuera de muestra de la validación cruzada.

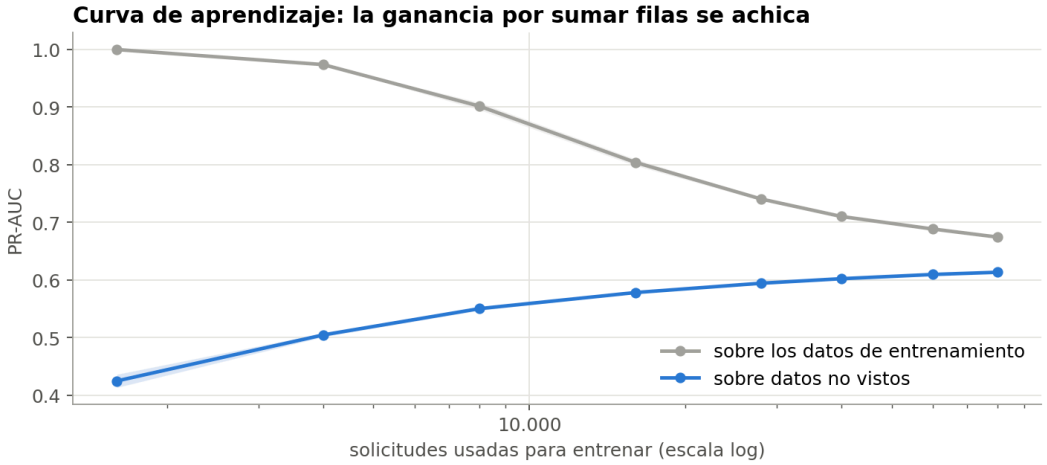


Figura B3. Curva de aprendizaje: PR-AUC según la cantidad de solicitudes de entrenamiento.

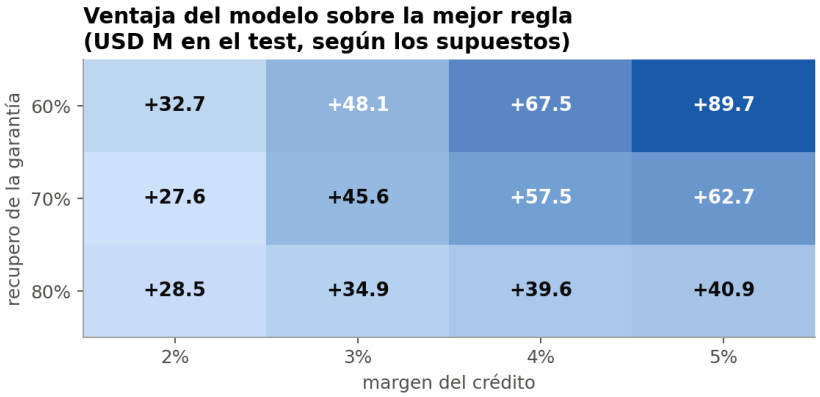


Figura B4. Ventaja del modelo sobre la mejor regla según margen y recupero (USD M en el test).

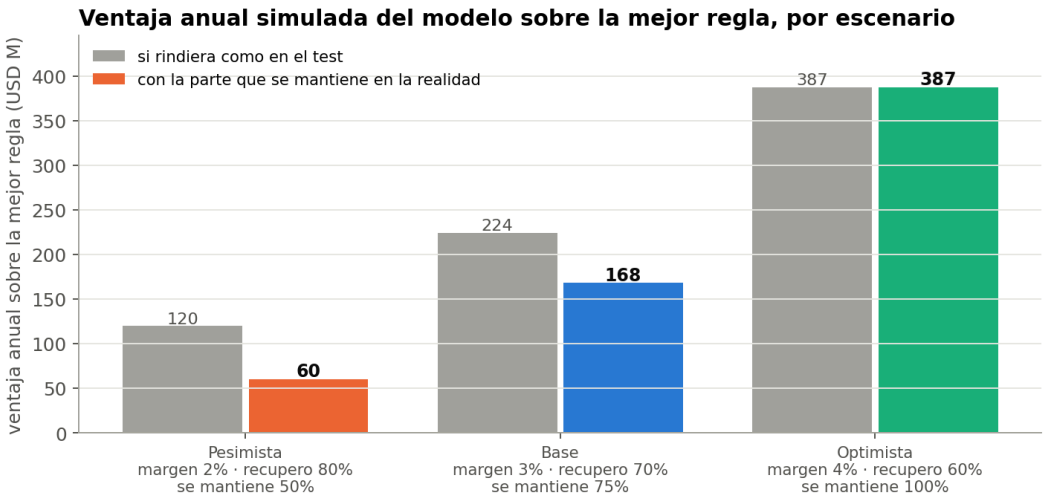


Figura B5. Ventaja anual simulada sobre la mejor regla en los tres escenarios.

Anexo C. Reproducibilidad y fuentes

Repositorio: https://github.com/pabloamagnino-coder/grupo24-utn-tpfinal. Contiene el notebook repo/Prediccion_mora_hipotecaria.ipynb ejecutado de punta a punta, requirements.txt, el README.md con instrucciones y la carpeta data/ con el dataset y el glosario de variables. El notebook corre local o en Google Colab en menos de 15 minutos, con semillas fijas.

Fuentes. Loan Default Dataset, Kaggle, usuario yasserh: https://www.kaggle.com/datasets/yasserh/loan-default-dataset · Campbell, J. Y., Giglio, S. y Pathak, P. (2011). Forced Sales and House Prices. *American Economic Review* 101(5) · Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS · Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD '16* · Lundberg, S. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 30* · Comité de Supervisión Bancaria de Basilea (2017). *Basilea III: finalización de las reformas poscrisis*. BPI · Interagency Guidelines for Real Estate Lending Policies, 12 CFR Parte 208, Apéndice C (EE.UU.) · Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR* 12 · Ley 25.326 de Protección de Datos Personales (Argentina).

Todas las figuras y tablas son de elaboración propia a partir del dataset citado.