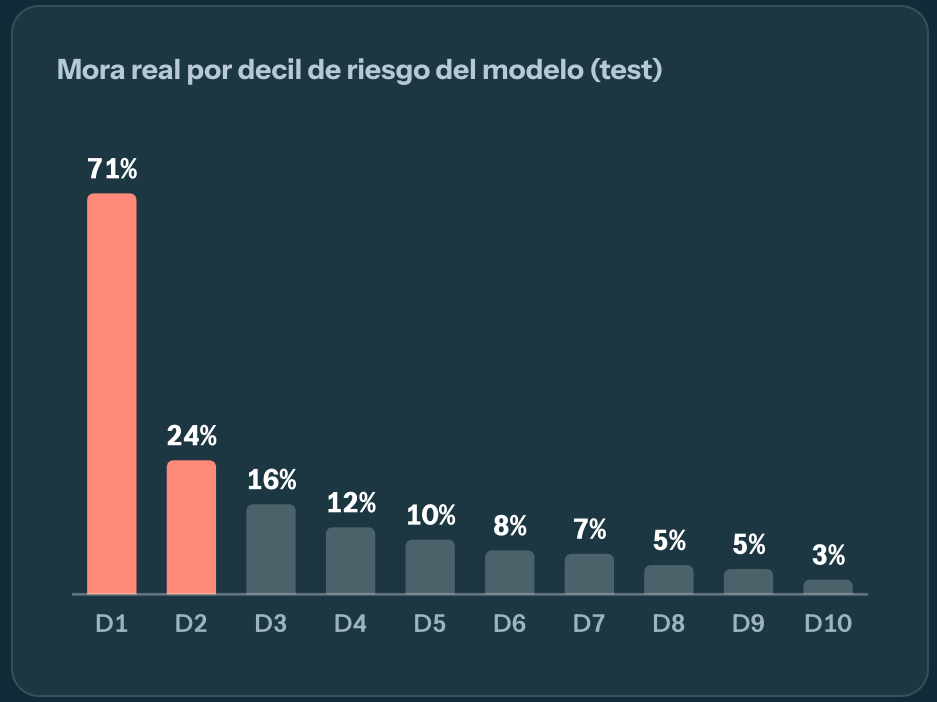
PROYECTO FINAL INTEGRADOR · ENTREGA FINAL

¿A quién le prestamos?

Predicción de mora en créditos hipotecarios para decidir la originación con criterio económico

Ailin Soriano · Fernanda Pardo · Pablo Magnino · Germán Langoni

Equipo N.° 24 · Diplomatura en Ciencia de Datos y Análisis Avanzado (UTN BA) · 26 de octubre de 2026



EL PROBLEMA

Cada solicitud es una apuesta con dos formas de perder

Llega una solicitud de crédito hipotecario y el área de riesgo tiene que aprobarla o rechazarla, antes de saber si se va a pagar.

Aprobar a quien no paga

El banco remata la casa, pero la vende con descuento, paga costos judiciales y espera años. Pierde parte del capital.

Falso negativo · el error más caro

Rechazar a quien habría pagado

El banco pierde el margen del crédito y el cliente se va a la competencia. Rechazar de más tampoco es gratis.

Falso positivo

84%

acierta decir siempre "paga", sin detectar ninguna mora

Por eso no optimizamos una métrica estadística sino el resultado económico: los dos errores medidos en dólares.

LOS DATOS

El hallazgo que cambió todo: un 10% de los datos era trampa



Buró EQUI (Equifax) o sin tasación: 100% en mora

148.670 solicitudes de 2019 · Loan Default Dataset (Kaggle)

42%

de todas las moras estaban en ese bloque

100 vs 16%

tasa de mora dentro del bloque y en el resto

133.337

solicitudes válidas para modelar, después de excluirlo

Ningún buró tiene clientes que no pagan el 100% de las veces, y ningún banco presta sin tasar la casa. Si el modelo ve ese bloque, aprende a reconocerlo y no a evaluar riesgo. Por eso decidimos excluirlo.

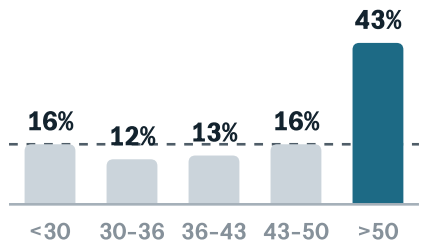
EXPLORACIÓN

Qué dicen los datos sobre nuestras cuatro hipótesis

Se sostiene

H1 · Deuda / ingreso

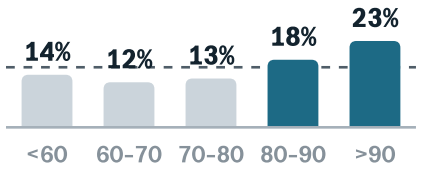
Tasa de mora por tramo de DTI (%)



Se sostiene, más suave

H2 · Garantía (LTV)

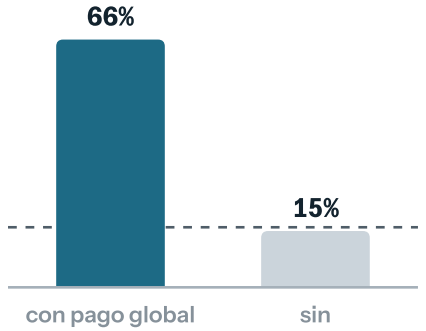
Tasa de mora por tramo de LTV (%)



La señal más fuerte

H3 · Tipo de producto

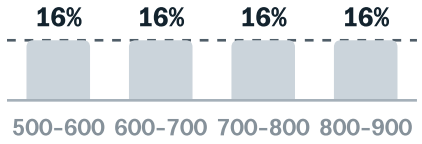
Con pago global al final y sin él



No se ve

H4 · Puntaje crediticio

Tasa de mora por tramo de score



Ninguna variable sola separa bien a los que pagan de los que no: la señal está en las combinaciones, que es justo donde un modelo le gana a una regla.

LA REGLA DE DECISIÓN

De una probabilidad a "aprobado" o "rechazado"

1

Probabilidad de mora

El modelo estima qué tan probable es que la solicitud no pague.

2

Cuánto duele si pasa

La garantía define la pérdida (LGD): suponemos que el banco recupera el 70% de la tasación.

3

Rechazar si conviene

Si la pérdida esperada supera a la ganancia esperada, se rechaza. Cada solicitud tiene su propio umbral.

4

Tope de 20%

Un corte fijo en dólares deja afuera como máximo a 1 de cada 5. Cada solicitud se decide sola.

Rechazar si $p \times LGD > (1 - p) \times margen$

pérdida esperada contra ganancia esperada · margen 3%

USD 1.204

corte fijo de pérdida esperada, calibrado en desarrollo

19,4%

de rechazo en el test (entre 18,2% y 20,2% por período)

2,9–37,5%

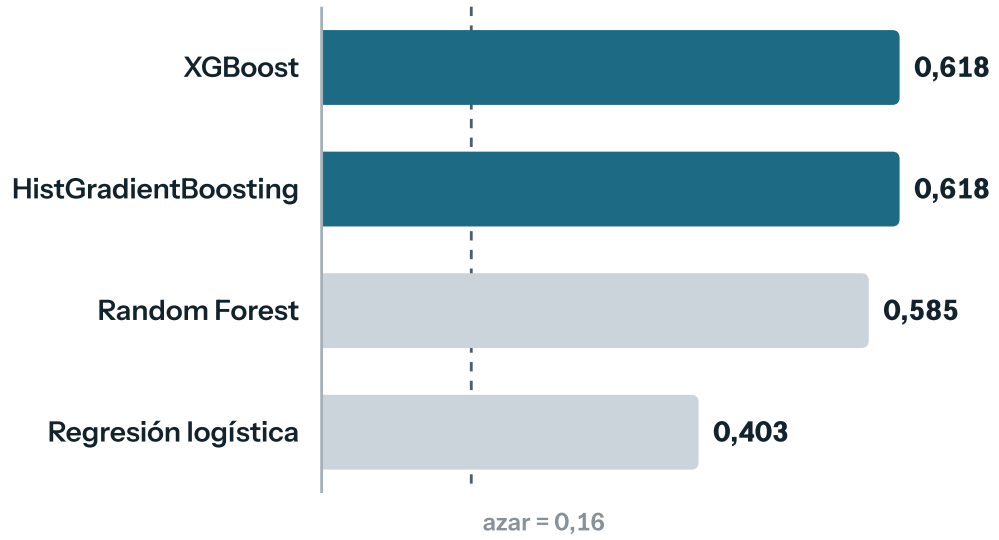
rango del umbral de probabilidad según la garantía

MODELADO

Cuatro modelos, comparados con validación cruzada

PR-AUC en validación cruzada (5 folds)

Qué tan bien ordena el riesgo, enfocado en las moras. El azar da 0,16.

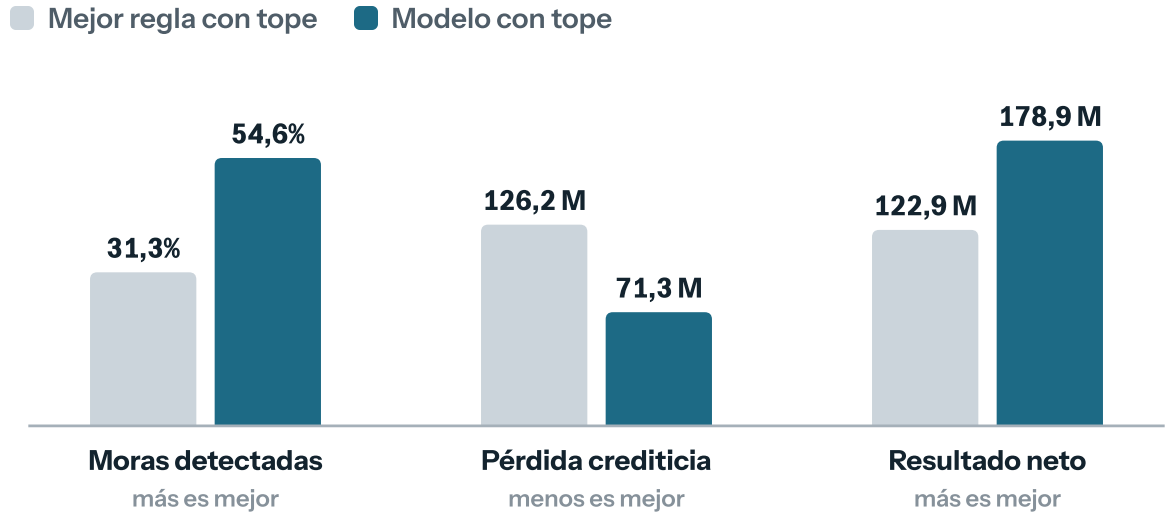


- **Métrica principal: PR-AUC** en validación cruzada. Con 16% de moras, la accuracy engaña.
- Entrenamos **sin dar más peso** a ninguna de las clases.
- Si la diferencia es chica frente a la variabilidad, los modelos rinden **parecido**: no elegimos por una ventaja marginal.
- **Los dos boosting empatan** (0,618): desempata la **calibración** (Brier) y elegimos XGBoost. La logística queda 22 puntos atrás.
- Las **15 configuraciones** de hiperparámetros rindieron igual que la de fábrica: para mejorar harían falta variables nuevas.

BENCHMARK

¿Le gana a una regla que un analista arma en una tarde?

Contra la mejor regla con LTV y deuda/ingreso (LTV > 95 o DTI > 50), elegida entre 143 combinaciones y con el mismo tope de 20%, sobre 33.335 solicitudes que el modelo nunca vio.



USD 56 M

de mejor resultado simulado sobre el test, con el mismo tope de rechazo

23% menos

pérdida que la mejor regla LTV/DTI, rechazando lo mismo (42% menos que la regla propuesta)

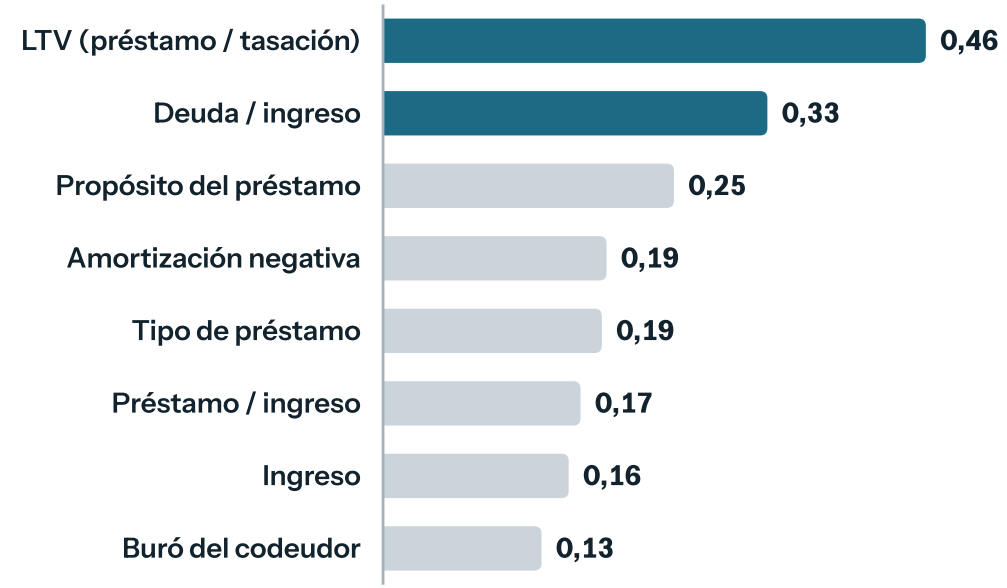
12 de 12 escenarios de margen y recupero con ventaja positiva

INTERPRETACIÓN (SHAP)

Qué mira el modelo, y qué aporta cada bloque

Las variables que más mueven la predicción

Impacto medio sobre la predicción (|SHAP|)



Si le sacamos cada bloque

Se reentrena el modelo sin esas variables (cambio en PR-AUC y en resultado)

H1	Capacidad de pago	**−12,4 p.p.** −USD 22,5 M
H3	Estructura del producto	**−10,4 p.p.** −USD 17,0 M
H2	Garantía (LTV, tasación)	**−6,6 p.p.** −USD 14,2 M
H4	Puntaje crediticio: no aporta	**+0,1 p.p.** −USD 0,3 M

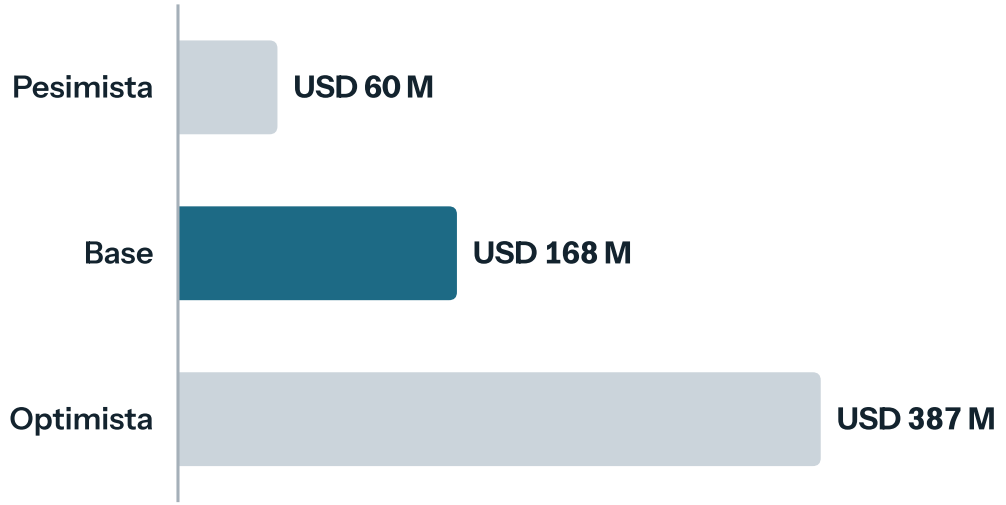
Excluimos **Credit_Worthiness** (no dependemos de la calificación del sistema actual) y **submission_of_application** (no sabemos qué significa). Cuestan menos del 3% del resultado.

IMPACTO EN EL NEGOCIO · SIMULACIÓN

Cuánta plata vale el modelo

Ventaja anual sobre la mejor regla (USD M)

133.337 solicitudes por año, el volumen del dataset



Margen 2–4% · recupero 60–80% · se mantiene en la realidad entre 50% y 100% de la ventaja del test

Neto año 1 · base

USD 126 M

incluye 3 meses de piloto sin beneficio

Neto 3 años · base

USD 462 M

entre USD 165 M (pesimista) y 1.065 M (optimista)

12 de 12

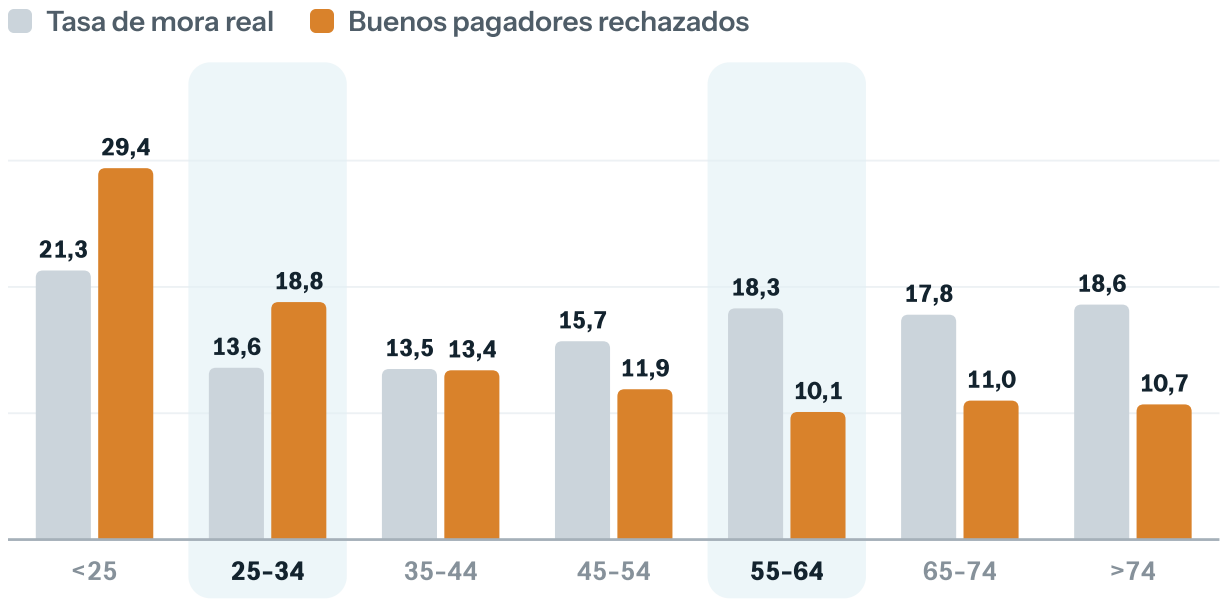
escenarios de margen (2% a 5%) y recupero (60% a 80%) con ventaja positiva sobre la mejor regla

No sumamos CAPEX ni OPEX: serían supuestos sin datos reales. El riesgo no es económico sino de validez: que el modelo rinda igual con datos reales del banco.

ÉTICA

¿A quién le toca el error?

Por grupo de edad (%)



El modelo no usa género ni edad

Los excluimos del modelo para no sesgarlo y los usamos solo para auditar a quién le toca el error.

Señal por edad

Los de 25–34 tienen **menos mora** (13,6%) pero **más buenos pagadores rechazados** (18,8% contra 10,1% de los de 55–64).

Nuestra lectura

No los rechaza por la edad sino porque ganan poco para lo que piden. No usamos umbrales por edad: lo declaramos como riesgo y se monitorea en cada reentrenamiento.

RIESGOS Y LIMITACIONES

Lo que todavía no sabemos

Datos en parte sintéticos

El puntaje crediticio no predice nada, algo imposible en un banco real.

→ **Reentrenar con datos reales del banco**

Sin fechas

Todo es de 2019: no pudimos probar si funciona en otro año.

→ **Validar en un período posterior y monitorear cada mes**

Supuestos económicos

Margen, recupero y seguro hipotecario no vienen en los datos.

→ **Sensibilidad en 12 escenarios; validar con finanzas**

Solo vemos a los aprobados

El banco nunca sabe si un rechazado habría pagado.

→ **Aprobar una pequeña cuota fuera del modelo**

Privacidad

Datos de personas y de su situación financiera.

→ **Minimización y control de accesos (Ley 25.326)**

El modelo entrena en segundos y puntúa en milisegundos: escala a cualquier volumen y se reutiliza para otros créditos con garantía.

RECOMENDACIÓN

Piloto antes de desplegar

55 vs 31%

moras detectadas por el modelo y por la mejor regla, con el mismo tope de rechazo

10%

del dataset era un artefacto: el hallazgo más importante fue de datos

0,621

PR-AUC en test, 3,9 veces el azar, con un modelo que podemos explicar

1

Reentrenar

Con datos reales y fechados del banco, para validar en un período posterior.

2

Validar supuestos

Margen y recupero con finanzas; el sesgo por edad con legales.

3

Piloto de 3 meses

El modelo recomienda y el analista decide. Escalar solo si confirma la ventaja.